УНИВЕРСИТЕТ ИТМО

Факультет прикладной информатики

Направление подготовки 09.03.03 Прикладная информатика

Образовательная программа «Мобильные и сетевые технологии»

Отчет по лабораторной работе 3

«Классика против LLM»

Автоматическая обработка текстов

Выполнила:

Архангельская Елизавета К3439

Поток: АвтОбрТекстов 1.1

Преподаватель:

Гусарова Наталия Федоровна

Санкт-Петербург,
2026 г.

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №3

1. Цель работы

Сравнить классический признаковый классификатор и генеративную языковую модель не только по качеству, но и по устойчивости, времени и стоимости обработки.

2. Подготовка данных

Выборки подготовлены из исходных файлов RuSentiment: 3000 текстов для обучения, 500 для валидации и 500 для тестирования. Оставлены классы positive, negative и neutral; удалены пропуски и точные дубликаты текстов. Разбиение выполнено с random_state=42; тестовые тексты взяты из исходной тестовой части. Пересечений текстов между выборками нет.

С помощью LLM сгенерирован стресс-набор (stress.csv) из 100 текстов: по 20 примеров с отрицанием, опечатками, иронией, цитированием и смешанной оценкой. Для каждого текста указаны метка тональности и категория сложности.

3. Бейслайн

В качестве бейслайна использован DummyClassifier со стратегией most_frequent. Он всегда предсказывает neutral — наиболее частый класс обучающей выборки. На тестовой выборке точность (accuracy) составила 64,2%. На стресс-наборе точность составила 30%. Результат соответствует доле neutral в каждой выборке, поскольку бейслайн не учитывает содержание текста.

4. TF-IDF и LogisticRegression

Построен Pipeline из TfidfVectorizer со словными n-граммами 1–2 и LogisticRegression. Модель обучалась на train. На validation проверены шесть комбинаций двух гиперпараметров: min_df (1 или 2) и C (0,5; 1; 2). По наибольшей accuracy выбраны min_df=2 и C=1; точность на validation составила 64,6%. На test точность составила 69,4%, на стресс-наборе — 38%. Тестовая выборка и стресс-набор не использовались для подбора параметров.

5. Классификация с помощью LLM

Для классификации 500 текстов test и 100 текстов стресс-набора использован LLM-ассистент. При чтении test.csv и stress.csv извлечён только первый столбец с текстами. Использована инструкция: «Определи тональность текста: positive, negative или neutral. Верни только JSON с единственным полем label». Примеры ответов в запрос не добавлялись. Результаты test сохранены в test_llm_predictions.json. Zero-shot классификация стресс-набора повторена в отдельном чате с инструкцией читать только тексты; новые ответы загружены из stress_zero_shot.json. В обоих файлах сохранён порядок строк, каждый ответ содержит только поле label. Предсказания test получены в текущем чате, без изолированных вызовов.

6. Few-shot классификация

Для few-shot варианта к той же инструкции добавлены шесть примеров из train: по два каждого класса. Использована та же LLM в текущем чате. Для классификации прочитан только столбец текстов test.csv и stress.csv. 500 и 100 ответов сохранены соответственно в test_llm_few_shot_predictions.json и stress_llm_few_shot_predictions.json в порядке строк, с единственным полем label. Ограничение предыдущего контекста чата сохраняется.

1. Текст: Еще одно успешное мероприятие в активе!

Ответ: {"label":"positive"}

2. Текст: А мне больше третий фильм понравился=)))))))))))))

Ответ: {"label":"positive"}

3. Текст: дернуть бы куда из депрессии.

Ответ: {"label":"negative"}

4. Текст: Без второй совы скучно(

Ответ: {"label":"negative"}

5. Текст: У квадратного стола отпилили один угол. Сколько теперь углов у него стало?

Ответ: {"label":"neutral"}

6. Текст: свалил на полигон. буду 2-го мая.

Ответ: {"label":"neutral"}

7. Сравнение

Для сравнения рассчитаны accuracy и macro-F1. Macro-F1 усредняет F1 трёх классов с одинаковым весом. Все четыре режима оценены на 500 текстах test и 100 текстах стресс-набора. Результаты приведены в таблице.

Таблица 1 — Сравнение качества классификации

Метод	**Test accuracy**	**Test macro-F1**	**Stress accuracy**	**Stress macro-F1**
Бейслайн	0,642	0,261	0,300	0,154
TF-IDF + LogisticRegression	0,694	0,501	0,380	0,313
LLM zero-shot	0,840	0,818	1,000	1,000
LLM few-shot	0,856	0,830	1,000	1,000

На test TF-IDF и LogisticRegression получили accuracy 69,4% и macro-F1 0,501. На стресс-наборе accuracy составила 38%, macro-F1 — 0,313. Новые zero-shot ответы из отдельного чата совпали со всеми 100 метками стресс-

набора: accuracy и macro-F1 равны 1. Сохранённые few-shot ответы также дали 1, но получены в чате, где создавался набор, и не являются независимой оценкой. На основном test accuracy zero-shot составила 84%, macro-F1 — 0,818. Для few-shot accuracy составила 85,6%, macro-F1 — 0,830. На этой выборке few-shot получил наибольшие значения обеих метрик. Zero-shot предсказания на стресс-наборе получены в отдельном чате.

8. Время обработки и токены

Для классических методов время предсказания пачки измерено через time.perf_counter и разделено на число текстов; обучение не включено. Для LLM выполнена повторная обработка в текущем чате. Интервалы от чтения данных или начала повторной обработки до сохранения ответов составили: zero-shot test — 32 с, stress — 9 с; few-shot test — 15 с, stress — 8 с. Это приблизительное время рабочего процесса с файловыми операциями и сохранённым контекстом, а не задержка отдельных запросов или измерение чистого времени генерации. Few-shot повторно использовал тексты из контекста; различие времени не доказывает преимущество этого режима по скорости.

Таблица 2 — Время обработки и оценка числа токенов

Метод	**Набор**	**Секунд на текст**	**Входные токены**	**Выходные токены**
Бейслайн	test	0,00000007	—	—
Бейслайн	stress	0,00000026	—	—
TF-IDF + LogisticRegression	test	0,00000689	—	—
TF-IDF + LogisticRegression	stress	0,00000748	—	—
LLM zero-shot	test	0,06400000	13358.0	2003.0
LLM zero-shot	stress	0,09000000	1623.0	403.0
LLM few-shot	test	0,03000000	13497.0	2003.0

LLM few-shot	stress	0,08000000	1762.0	403.0

Число токенов оценено с помощью tiktoken и кодировки o200k_base по восстановленному видимому промпту (инструкция, примеры для few-shot и пачка текстов) и компактному JSON ответов. Значения в таблице относятся ко всей пачке. Они не являются фактическим расходом сервиса: скрытый контекст, рассуждения и служебные сообщения не включены. Инструкция и примеры посчитаны один раз на пачку, а не для каждого текста. Стоимость 1000 текстов не рассчитана: тариф API для данного чат-прогона отсутствует.

9. Разбор ошибок

Разобраны 15 разных текстов из test: пять ошибок TF-IDF, пять ошибок LLM в режиме few-shot и пять расхождений между этими методами. Ошибкой считается несовпадение с меткой корпуса. Причины ниже являются интерпретацией результатов, а не наблюдением внутренних рассуждений моделей. ID — номер текста в test.csv без заголовка, начиная с 1; это локальный идентификатор, а не исходный ID RuSentiment.

Ошибка TF-IDF

1. ID: 4. Текст: «Хах.Фагот!!!)))»

Метки: исходная: positive; TF-IDF: neutral; LLM few-shot: positive.

Короткая эмоциональная реплика с нестандартным словом и скобками. Положительный тон выражен слабо для словных признаков.

2. ID: 8. Текст: «Как говорится, люди смеются, чтобы не заплакать....»

Метки: исходная: negative; TF-IDF: neutral; LLM few-shot: negative.

Смех противопоставлен желанию заплакать. Классификатор не распознал отрицательный смысл выражения.

3. ID: 13. Текст: «таааааааааааак

приму в дар ВИРУС КАРД))))

вот и знаю, что хочу на новый год хД»

Метки: исходная: neutral; TF-IDF: positive; LLM few-shot: neutral.

Запрос подарка со скобками и «хД» принят за положительную оценку, хотя исходная метка neutral.

4. ID: 75. Текст: «Неплохая статья про детей и летний отдых.»

Метки: исходная: positive; TF-IDF: neutral; LLM few-shot: positive.

Слово «неплохая» выражает положительную оценку. Модель отнесла короткую реплику к neutral.

5. ID: 134. Текст: «Самая последняя спетая Михой песня ..... Грустно .....»

Метки: исходная: negative; TF-IDF: positive; LLM few-shot: negative.

Прямой маркер «Грустно» не перевесил другие признаки: вместо negative предсказан positive.

Ошибка LLM few-shot

1. ID: 22. Текст: «Звездабол он, у него 15 октября др)»

Метки: исходная: neutral; TF-IDF: neutral; LLM few-shot: negative.

LLM восприняла оскорбительное слово как отрицательную оценку. В корпусе реплика имеет метку neutral; случай неоднозначен.

2. ID: 48. Текст: «хиии)) такой зелёненький)»

Метки: исходная: positive; TF-IDF: neutral; LLM few-shot: neutral.

Уменьшительная форма и смех передают доброжелательное отношение, но LLM выбрала neutral. Без изображения контекст неполон.

3. ID: 56. Текст: «Жду не дождусь своё вино)»

Метки: исходная: neutral; TF-IDF: neutral; LLM few-shot: positive.

Ожидание вина интерпретировано как радость. По исходной разметке это neutral; модель добавила эмоциональную оценку.

4. ID: 57. Текст: «Так! Что за подстава? Теперь контакт палит музыку, которую ты в данный момент слушаешь?!»

Метки: исходная: neutral; TF-IDF: neutral; LLM few-shot: negative.

Слова «подстава» и вопросительные знаки интерпретированы как недовольство. Исходная метка neutral; граница с negative неоднозначна.

5. ID: 63. Текст: «10 часов(жалко что короткое XD»

Метки: исходная: neutral; TF-IDF: neutral; LLM few-shot: negative.

LLM опиралась на слово «жалко» и грустную скобку, выбрав negative. Исходная метка neutral; смех XD делает тон смешанным.

Расхождение

1. ID: 39. Текст: «Ну ты понял,да?))))»

Метки: исходная: neutral; TF-IDF: positive; LLM few-shot: neutral.

TF-IDF выбрал positive из-за эмоционального оформления; LLM сохранила neutral, совпав с меткой корпуса.

2. ID: 80. Текст: «Теперь у меня другой адресс=))рядом с офисом=))»

Метки: исходная: neutral; TF-IDF: positive; LLM few-shot: neutral.

Сообщение о смене адреса содержит улыбки, но не явную оценку. LLM совпала с neutral, TF-IDF выбрал positive.

3. ID: 85. Текст: «Вроде все нормально, но душу рвет на части. ☹»

Метки: исходная: negative; TF-IDF: neutral; LLM few-shot: negative.

Оборот «но душу рвет на части» задаёт отрицательную тональность. LLM распознала её, TF-IDF выбрал neutral.

4. ID: 97. Текст: «хаха

а в подписках то первый кэп)»

Метки: исходная: neutral; TF-IDF: neutral; LLM few-shot: positive.

TF-IDF совпал с neutral. LLM расценила «хаха» как положительную эмоцию; без контекста это неоднозначно.

5. ID: 114. Текст: «хочуууууууу фоткаться(((*»

Метки: исходная: positive; TF-IDF: neutral; LLM few-shot: negative.

TF-IDF выбрал neutral, LLM — negative; оба не совпали с positive. Желание фотографироваться сочетается с грустными скобками.

10. Рекомендации

Массовая обработка

Для большого количества текстов лучше использовать TF-IDF и LogisticRegression. Модель работает локально, быстро обрабатывает пачки и не требует оплаты внешних запросов. На test accuracy составила 69,4%, macro-F1 — 0,501. При необходимости повысить качество можно направлять тексты с низкой уверенностью классификатора на дополнительную обработку LLM; такой комбинированный вариант в этой работе не проверялся.

Небольшой поток сложных текстов

Для небольшого потока с отрицанием, иронией и смешанной оценкой рекомендуется LLM с few-shot промптом. На test этот вариант получил accuracy 85,6% и macro-F1 0,830, выше остальных исследованных режимов. Шесть примеров помогают задать границы классов. Перед практическим применением результат следует проверить отдельными вызовами на новых текстах: текущие чат-прогоны не обеспечивают изоляцию контекста, а приблизительные замеры времени не позволяют достоверно сравнить скорость zero-shot и few-shot.

Локальная обработка без внешнего API

Рекомендуется TF-IDF и LogisticRegression: после обучения модель и векторизатор можно сохранить и применять без подключения к внешним сервисам. Тексты остаются на локальном компьютере, для предсказания не нужна генеративная модель. Локальная LLM может быть альтернативой для сложных текстов, но потребует скачивания весов и подходящего оборудования; её качество и скорость в этой работе не измерялись.

11. Вывод

В работе сравнены бейслайн, TF-IDF с LogisticRegression и два режима LLM. На основном test наибольшее качество показал few-shot: accuracy 85,6% и macro-F1 0,830. TF-IDF получил accuracy 69,4% и macro-F1 0,501, при этом быстро выполнял предсказания локально. Разбор ошибок показал трудности классического метода с косвенной оценкой и эмоциональным оформлением, а LLM — с неоднозначными короткими репликами и границей между neutral и выраженной эмоцией. Для массовой и локальной обработки лучше использовать TF-IDF с LogisticRegression, а для небольшого потока сложных текстов — LLM с few-shot промптом.